

LLM 自动化测评

Agent 一改 Prompt / 知识就要人肉点测——慢、标准因人而异、很难闭环。用「用户智能体施压 + 裁判智能体打分」把回归变成可复现资产，效率从天级压到分钟级。

- 效果评测
- 双智能体闭环
- Markdown 配置
- 开源可跑

查看 [GitHub](https://github.com/G-LJH/FastGPT-Agent-Tester) <https://github.com/G-LJH/FastGPT-Agent-Tester>

背景与问题

在 FastGPT 上搭完智能体，真正卡交付的往往不是「能不能答」，而是**改完敢不敢全量回归**。人工逐条对话贵、慢、不可复现，评测结果也很难直接变成下一步改 Prompt / 知识的动作。

我要解决的

把评测从一次性人工劳动，变成可配置、可复跑、能指导优化的资产。

可验证结果

批量对弈 + 多维报告；回归耗时从天级缩短到分钟级。

三个关键判断

01 · 机制

用 Agent 测 Agent

用户智能体负责多轮施压，裁判智能体按统一标尺打分——评测本身也是一套可交付能力。

02 · 交付

配置大于改代码

用 Markdown 声明话题、轮数与评分标准，让交付同学能复用，而不是每次找开发改脚本。

03 · 闭环

报告必须能指导下一步

输出薄弱点与 Prompt 优化建议，避免「只有分数、没有动作」的假评测。

我怎么做

- **设计闭环：**配置加载 → 用户智能体提问 → FastGPT 回复 → 裁判打分 → 汇总与优化建议。
 - **声明式方案：**测试话题与评分标准写在 Markdown，例如曾用于医生助手类场景的配置样例。
- **实现框架：**异步多轮、批量任务队列；面向 FastGPT API 的可复用客户端。
 - **证据输出：**自动生成概览与多维评分报告，方便对比改配置前后的差异。

结果

- 形成可开源运行的测评框架（见 GitHub README 与配置样例）
- 回归效率：人工天级 → 自动**分钟级**

- ## 证据



一次批量跑完后的结果总览——证明评测可复现、可留档

按维度看短板，直接服务 Prompt / 知识迭代，而不是只给一个总分

技术栈

- Python · AsyncIO · FastGPT API · 多智能体（用户 / 裁判 / 优化建议）

开源仓库: FastGPT-Agent-Tester。安装与环境变量说明见仓库, 本页只讲「为什么做、怎么判断、跑出什么」。与医生助手等交付场景可组合使用。